



UAX

Universidad
Alfonso X el Sabio

FACULTAD DE BUSINESS AND TECH

MÁSTER EN BIOINFORMÁTICA

MEMORIA DE PRÁCTICAS

**DESARROLLO DE UN PIPELINE BIOINFORMÁTICO
REPRODUCIBLE PARA LA PRIORIZACIÓN DE GENES
CANDIDATOS EN GLOMERULONEFRITIS MEDIANTE
EL ANÁLISIS DE DATOS ESTRUCTURADOS DE
EXPRESIÓN GÉNICA.**

CRISTIAN ARIAS RAMIREZ

NP 870902

Tutor empresarial: Lic. Eduviges Ramírez
Tutor académico: Julio Mérelo

ÍNDICE DE CONTENIDOS

1. INTRODUCCIÓN	3
2. OBJETIVOS	4
3. DESCRIPCION DE LA EMPRESA	4
4. DESCRIPCIÓN DE LA ACTIVIDAD	5
4.1 HERRAMIENTAS Y ENTORNO DE TRABAJO.....	6
5. ACTIVIDADES REALIZADAS	6
5.1 Semana 1	7
5.2 Semana 2	9
5.3 Semana 3	10
5.4 Semana 4	11
5.5 Semana 5	13
5.6 Semana 6	14
6. RESULTADOS	15
6.1 LIMITACIONES	20
7. CONCLUSIONES	21
8. BIBLIOGRAFÍA	23

1. INTRODUCCIÓN

El presente documento recoge la memoria de prácticas del Máster en Bioinformática, desarrolladas en el entorno del centro CEPIED, con un enfoque orientado al análisis y aplicación de herramientas bioinformáticas en el estudio de enfermedades renales.

Dado que el centro no dispone de infraestructura para la generación de datos ómicos, el proyecto se desarrolló en un contexto *in silico*, utilizando datasets públicos y estructurados de expresión génica. Este enfoque permitió simular un entorno real de análisis bioinformático, garantizando la reproducibilidad del flujo de trabajo y la aplicabilidad de los resultados.

El estudio se centró en la glomerulonefritis, un grupo de enfermedades renales de alta relevancia clínica, caracterizadas por su potencial progresión hacia enfermedad renal crónica. Desde una perspectiva biomédica, la identificación de genes implicados en estos procesos resulta fundamental para mejorar la comprensión de los mecanismos fisiopatológicos subyacentes.

El objetivo principal del proyecto fue desarrollar un pipeline reproducible en Python para la priorización de genes candidatos, integrando variables clave como el cambio de expresión génica, la significación estadística y la relevancia renal.

El desarrollo del pipeline se llevó a cabo de forma progresiva, partiendo de un dataset de prueba y evolucionando hacia la integración de datos externos y el uso de herramientas complementarias en R. Este enfoque permitió aplicar de manera práctica los conocimientos adquiridos durante el máster, en un contexto alineado con las metodologías actuales en bioinformática.

2. OBJETIVOS

OBJETIVO GENERAL:

Desarrollar un pipeline bioinformático reproducible orientado a la priorización de genes en glomerulonefritis.

OBJETIVOS ESPECÍFICOS:

- Implementar un pipeline reproducible en Python para el procesamiento y priorización de genes asociados a glomerulonefritis.
- Integrar herramientas bioinformáticas en R para análisis exploratorio de expresión diferencial.
- Generar un ranking estructurado de genes basado en criterios de expresión génica, significación estadística y relevancia renal.
- Incorporar mecanismos de validación y trazabilidad que permitan garantizar la reproducibilidad del flujo de trabajo.

3. DESCRIPCIÓN DE LA EMPRESA

CEPIED es un centro de atención sanitaria orientado al manejo integral de pacientes con enfermedades crónicas, incluyendo patologías renales, hipertensión arterial y diabetes mellitus. El centro desarrolla actividades asistenciales, de seguimiento clínico, prevención y educación en salud, con un enfoque centrado en la atención integral del paciente y la promoción de hábitos saludables.

Dentro de su actividad asistencial, CEPIED participa en la atención y seguimiento de pacientes con enfermedad renal crónica, factores de riesgo cardiovascular y otras patologías de alta prevalencia en la práctica clínica. Esta orientación permitió contextualizar el presente proyecto dentro de un entorno clínico real, identificando necesidades relacionadas con el análisis e interpretación de información biomédica aplicada a enfermedades renales.

Aunque el centro no dispone de infraestructura propia para la generación de datos ómicos, su actividad clínica proporcionó un marco adecuado para el desarrollo de un proyecto bioinformático de carácter in silico. En este contexto, se emplearon datasets públicos y estructurados con fines formativos, permitiendo aplicar metodologías bioinformáticas reproducibles orientadas a la priorización de genes en glomerulonefritis.

Este entorno facilitó la integración de conocimientos clínicos y computacionales, favoreciendo el desarrollo de competencias en análisis de datos, reproducibilidad y bioinformática aplicada a la nefrología.

4. DESCRIPCIÓN DE LA ACTIVIDAD

La actividad desarrollada durante el periodo de prácticas se centró en el diseño e implementación de un pipeline bioinformático reproducible orientado a la priorización de genes candidatos en glomerulonefritis.

El proyecto surgió de la necesidad de integrar herramientas computacionales en el análisis de enfermedades renales, con el objetivo de facilitar la identificación de genes potencialmente relevantes en procesos fisiopatológicos complejos. Desde una perspectiva biomédica, este tipo de aproximaciones permite generar hipótesis de investigación y apoyar la interpretación de datos biológicos en entornos de análisis in silico.

A nivel técnico, el trabajo consistió en la construcción progresiva de un flujo de trabajo en Python capaz de procesar datos estructurados de expresión génica, aplicar criterios de clasificación y generar salidas estandarizadas en formato TSV. Inicialmente, el pipeline se basó en criterios simples de significación estadística y cambio de expresión génica, evolucionando posteriormente hacia un modelo de priorización basado en un sistema de scoring reproducible e interpretable.

El desarrollo incluyó la validación de resultados mediante comparación con salidas esperadas (expected outputs), el registro detallado de las ejecuciones mediante runlogs y el uso de control de versiones con Git, garantizando la trazabilidad y reproducibilidad del proceso. Asimismo, se implementaron mecanismos de organización estructurada de datos, scripts y resultados para facilitar la reutilización y mantenimiento del flujo de trabajo.

De forma complementaria, se incorporaron herramientas de visualización para facilitar la interpretación de los resultados obtenidos. Asimismo, se realizó una aproximación exploratoria al uso de herramientas estándar de análisis transcriptómico en R, incluyendo *limma* y la revisión conceptual de flujos de trabajo basados en *DESeq2*. Esta actividad tuvo un carácter formativo y permitió familiarizarse con metodologías ampliamente utilizadas en el análisis de expresión diferencial, complementando el pipeline principal desarrollado en Python.

En conjunto, la actividad desarrollada permitió aplicar de forma práctica conocimientos de programación, análisis de datos y bioinformática, consolidando un flujo de trabajo reproducible orientado a la priorización génica y a la interpretación biológica de resultados en un contexto relacionado con enfermedades renales.

4.1 HERRAMIENTAS Y ENTORNO DE TRABAJO

El pipeline fue desarrollado principalmente en Python, utilizando librerías como *pandas* para la manipulación de datos tabulares y *matplotlib* para la generación de visualizaciones. La ejecución y automatización del flujo de trabajo se realizó mediante PowerShell en entorno Windows, permitiendo registrar la trazabilidad de las ejecuciones mediante archivos de registro (*runlogs*).

De forma complementaria, se realizaron actividades exploratorias en R orientadas a la comprensión de metodologías de análisis transcriptómico, incluyendo el uso de *limma* y la revisión conceptual de flujos de trabajo basados en *DESeq2*. Estas actividades tuvieron un carácter formativo y permitieron ampliar la comprensión de herramientas ampliamente utilizadas en el análisis de expresión diferencial.

El control de versiones del proyecto se realizó mediante Git, garantizando la trazabilidad de los cambios y la reproducibilidad del desarrollo. Asimismo, la estructura del proyecto fue organizada en carpetas independientes para scripts, datos de entrada, resultados, documentación y registros de ejecución, siguiendo buenas prácticas de reproducibilidad bioinformática.

Con el objetivo de garantizar la transparencia, trazabilidad y reproducibilidad del trabajo desarrollado durante las prácticas, el código fuente, la documentación, los datos de ejemplo y los resultados generados se encuentran disponibles en un repositorio público de GitHub:

Repositorio del proyecto:

<https://github.com/broncox456/gn-gene-prioritization-pipeline>

La disponibilidad del repositorio permite la revisión del flujo de trabajo implementado, la reutilización de los scripts desarrollados y la reproducción de los resultados obtenidos durante el proyecto.

Herramienta	Función principal
Python	Desarrollo del pipeline bioinformático
pandas	Procesamiento y manipulación de datos
matplotlib	Generación de visualizaciones
PowerShell	Automatización y ejecución reproducible
Git	Control de versiones y trazabilidad
R	Actividades exploratorias de análisis transcriptómico
limma	Introducción al análisis de expresión diferencial
DESeq2	Revisión conceptual de flujos de análisis RNA-seq

Tabla 1. Herramientas utilizadas en el desarrollo del pipeline bioinformático.

Resumen de las tecnologías empleadas para el procesamiento de datos, automatización, control de versiones y actividades formativas de análisis transcriptómico.

5. ACTIVIDADES REALIZADAS

5.1 SEMANA 1

Durante la primera semana se llevó a cabo el planteamiento inicial del proyecto, definiendo como objetivo principal el desarrollo de un pipeline bioinformático reproducible orientado a la priorización de genes en glomerulonefritis.

Se inició con la organización estructural del proyecto, estableciendo una jerarquía de carpetas que separa de forma clara los scripts, los datos de entrada, los resultados y la documentación. Este enfoque permitió garantizar desde el inicio la trazabilidad del análisis y facilitar la reproducibilidad del flujo de trabajo.

Asimismo, se implementaron mecanismos básicos de reproducibilidad, incluyendo control de versiones mediante Git, validación de salidas mediante expected outputs y registro de ejecuciones a través de runlogs generados desde PowerShell. Estas medidas permitieron mantener consistencia entre las distintas fases del desarrollo y asegurar trazabilidad durante la ejecución del pipeline.

Posteriormente, se diseñó un dataset de prueba compuesto por un conjunto reducido de genes asociados a patología renal. Para cada gen se incluyeron variables relevantes en el análisis de expresión génica, como el log2 fold change, el valor p ajustado y una categorización de relevancia renal. Este dataset permitió simular un escenario controlado sobre el cual validar el comportamiento inicial del pipeline antes de su aplicación potencial a datasets transcriptómicos de mayor complejidad.

A continuación, se desarrolló un primer script en Python encargado de leer los datos de entrada, procesarlos y clasificar los genes según criterios básicos de significación estadística y dirección del cambio de expresión. Como resultado, se generó una salida estandarizada en formato TSV, facilitando su posterior análisis e interpretación.

Durante esta fase surgieron dificultades relacionadas con la configuración del entorno de trabajo, particularmente en el reconocimiento de Python desde PowerShell, la configuración inicial del entorno de ejecución y la inicialización del repositorio con Git. Estas incidencias se resolvieron mediante pruebas iterativas, revisión de comandos y validación manual de los resultados, permitiendo estabilizar progresivamente el entorno de desarrollo.

Finalmente, se realizó una validación funcional del pipeline mediante la comparación de la salida generada con un expected output previamente definido, confirmando la consistencia y reproducibilidad de los resultados obtenidos.

En conjunto, esta primera semana permitió establecer las bases técnicas, organizativas y metodológicas del proyecto, sentando un marco sólido para el desarrollo progresivo de fases posteriores del pipeline bioinformático.

5.2 SEMANA 2

Durante la segunda semana se abordó la mejora del modelo inicial, con el objetivo de evolucionar desde un sistema de clasificación basado en reglas simples hacia un enfoque cuantitativo de priorización de genes.

En primer lugar, se revisó el comportamiento del script desarrollado en la semana anterior, identificando las limitaciones de utilizar categorías discretas para describir la relevancia biológica de los genes. A partir de esta evaluación, se planteó la necesidad de incorporar una métrica que permitiera establecer un ranking continuo de priorización.

Se implementó una nueva variable denominada “score de priorización”, calculada a partir del valor absoluto del log2 fold change, la significación estadística (valor p ajustado) y un peso asignado según la relevancia renal de cada gen. Este enfoque permitió transformar el análisis en un sistema de ranking, facilitando la identificación de los genes potencialmente más relevantes.

Desde el punto de vista metodológico, se optó por un modelo basado en reglas y scoring, priorizando la interpretabilidad, la trazabilidad del proceso y la coherencia con un entorno clínico formativo. Esta decisión permitió mantener un equilibrio entre simplicidad y utilidad analítica.

A nivel de implementación, se modificó el script en Python para integrar el cálculo del score y ordenar los resultados en función de dicha métrica, generando una salida estructurada que refleja el ranking de genes priorizados.

Durante esta fase surgieron dificultades relacionadas con el manejo de tipos de datos y la transformación de valores numéricos, particularmente en el tratamiento del valor p ajustado. Estos problemas se resolvieron mediante ajustes en el código y validación iterativa del comportamiento del pipeline.

La ejecución final confirmó que el nuevo sistema de priorización mejoraba la capacidad de interpretación de los resultados, permitiendo identificar de forma más precisa los genes de mayor interés biológico.

En conjunto, esta segunda semana representó un avance significativo hacia un enfoque más cercano a la práctica real en bioinformática, incorporando criterios cuantitativos y mejorando la robustez del análisis.

5.3 SEMANA 3

Durante la tercera semana se incorporaron herramientas de visualización con el objetivo de mejorar la interpretación de los resultados generados por el pipeline.

Partiendo del modelo de priorización desarrollado en la fase anterior, se consideró necesario representar los datos de forma gráfica para facilitar la identificación de los genes más relevantes. Para ello, se implementó un módulo adicional en Python utilizando librerías de visualización, capaz de generar gráficos a partir de la salida del pipeline.

En concreto, se desarrolló una representación gráfica de los genes mejor posicionados según el score de priorización, permitiendo observar de manera más intuitiva los candidatos con mayor relevancia en el contexto de la glomerulonefritis. Esta visualización facilitó la validación de los resultados y permitió identificar patrones de interés en los datos.

Durante la implementación surgieron dificultades relacionadas con la lectura y manipulación del archivo TSV, así como con la correcta selección de los genes con mayor puntuación. Estos problemas se resolvieron mediante ajustes en el preprocesamiento de los datos y validación iterativa del comportamiento del script.

Asimismo, se realizaron modificaciones en el formato de salida del pipeline para asegurar su compatibilidad con el módulo de visualización, permitiendo integrar ambas funcionalidades dentro de un mismo flujo de trabajo.

La generación de estas representaciones gráficas permitió complementar el análisis cuantitativo con una interpretación más accesible, reforzando la coherencia y utilidad del pipeline desde un punto de vista aplicado.

En conjunto, esta fase supuso un avance significativo al incorporar una capa visual al análisis, mejorando la interpretabilidad de los resultados y aproximando el proyecto a un entorno bioinformático más realista.

5.4 SEMANA 4

Durante la cuarta semana se incorporaron datos externos con características similares a las utilizadas habitualmente en repositorios transcriptómicos públicos, con el objetivo de evaluar el comportamiento del pipeline en un escenario más cercano a la práctica bioinformática aplicada.

Se trabajó con datasets estructurados que incluían variables habituales del análisis de expresión génica, como log2 fold change, valores p ajustados y anotaciones génicas. Estos archivos fueron diseñados y adaptados con fines formativos y reproducibles, permitiendo validar el funcionamiento del pipeline bajo condiciones más cercanas a un entorno transcriptómico aplicado.

Durante esta fase se utilizaron archivos estructurados en formato TSV, incluyendo datasets denominados `geo_mock_dataset.tsv` y `geo_real_dataset.tsv`, empleados como aproximaciones controladas a estructuras de datos inspiradas en repositorios transcriptómicos públicos. Es importante señalar que estos archivos no corresponden a matrices transcriptómicas descargadas directamente de GEO (Gene Expression Omnibus), sino a datasets estructurados con formato inspirado en este tipo de repositorios y utilizados con fines exclusivamente formativos para validar el comportamiento del pipeline. Estos archivos permitieron comprobar la capacidad del flujo de trabajo para adaptarse a distintos formatos de entrada manteniendo consistencia en las salidas generadas.

La integración de estos datos requirió procesos de estandarización de nombres de columnas, validación de formatos tabulares y verificación de consistencia entre variables numéricas y categóricas. Asimismo, fue necesario adaptar determinados componentes del pipeline para garantizar la compatibilidad con estructuras de datos más complejas que las utilizadas en las fases iniciales del proyecto.

La manipulación y validación de los datos se realizó principalmente mediante Python y la librería pandas, permitiendo automatizar procesos de lectura, normalización y verificación estructural de los archivos utilizados.

Durante esta fase surgieron dificultades relacionadas con la heterogeneidad de los datos, especialmente en la nomenclatura de variables, la organización de archivos y la consistencia estructural entre tablas. Estas incidencias se resolvieron mediante procesos de normalización, validación iterativa y ajustes específicos en el código desarrollado.

Adicionalmente, se reforzaron los mecanismos de reproducibilidad mediante la validación de salidas, la organización estructurada de carpetas, el control de versiones con Git y la ejecución controlada desde PowerShell, permitiendo mantener la trazabilidad durante todo el proceso de integración.

Posteriormente, se verificó que las salidas generadas conservaran coherencia estructural respecto a las fases iniciales del proyecto, confirmando que la incorporación de nuevos datos no comprometía la reproducibilidad ni la estabilidad del flujo de trabajo.

Una vez completada la adaptación de los datasets externos, se ejecutó el pipeline completo, confirmando su correcto funcionamiento y validando su capacidad para procesar estructuras de datos más complejas que las utilizadas inicialmente.

Esta etapa permitió evolucionar desde un entorno completamente controlado hacia un contexto más aplicado, evidenciando la robustez del pipeline frente a variaciones en la estructura y organización de los datos.

En conjunto, la incorporación de datasets estructurados inspirados en formatos transcriptómicos públicos representó un paso importante en la validación funcional del pipeline, reforzando su aplicabilidad desde una perspectiva formativa y aproximándolo a un entorno bioinformático reproducible, estructurado y técnicamente más sólido.

5.5 SEMANA 5

Durante la quinta semana se realizó una aproximación exploratoria al uso de herramientas estándar empleadas en análisis transcriptómico mediante el entorno R, con el objetivo de complementar los conocimientos adquiridos durante el desarrollo del pipeline en Python.

Esta fase tuvo un carácter principalmente formativo, orientado a comprender los fundamentos metodológicos del análisis de expresión diferencial y familiarizarse con herramientas ampliamente utilizadas en bioinformática, como limma y los flujos de trabajo habitualmente asociados a DESeq2. Asimismo, se revisó literatura metodológica relacionada con limma, edgeR y DESeq2 para contextualizar su aplicación en estudios transcriptómicos.

Durante esta etapa se exploraron conceptos relacionados con la identificación de genes diferencialmente expresados, la interpretación de resultados estadísticos y la generación de tablas exportables susceptibles de ser integradas en flujos de análisis reproducibles.

Las principales dificultades estuvieron relacionadas con la instalación de paquetes, la configuración del entorno de trabajo y la correcta interpretación de la documentación técnica asociada a estas herramientas. Estas incidencias fueron resueltas mediante revisión bibliográfica, consulta de documentación oficial y realización de pruebas exploratorias.

A pesar de su carácter introductorio, esta etapa permitió ampliar la comprensión de metodologías transcriptómicas utilizadas habitualmente en investigación biomédica y establecer una conexión conceptual entre los análisis de expresión diferencial y los procesos de priorización génica desarrollados en el pipeline principal.

Asimismo, se reforzó la importancia de la reproducibilidad, la documentación adecuada de los procedimientos y la necesidad de mantener coherencia entre las distintas etapas de un flujo bioinformático.

En conjunto, esta semana permitió ampliar el alcance formativo del proyecto, incorporando conceptos fundamentales del análisis transcriptómico y proporcionando una visión más completa de las herramientas utilizadas actualmente en bioinformática.

5.6 SEMANA 6

Durante la sexta y última semana se llevó a cabo la integración final de todos los componentes desarrollados a lo largo del proyecto, así como la interpretación de los resultados obtenidos desde una perspectiva bioinformática y clínica.

En esta fase se revisó el pipeline completo, desde la entrada de datos hasta la generación de resultados, asegurando que cada uno de los pasos funcionara de forma coherente dentro de un mismo flujo de trabajo. Se verificó la compatibilidad entre los resultados obtenidos durante las distintas fases del proyecto y su integración dentro del flujo de trabajo desarrollado en Python. Se realizó una revisión de los genes priorizados, prestando especial atención a aquellos con mayor puntuación en el score definido previamente. A partir de estos resultados, se llevó a cabo una interpretación general en el contexto de la glomerulonefritis, considerando su posible relación con procesos inflamatorios, daño glomerular y progresión de la enfermedad renal. Asimismo, se evaluaron las limitaciones del proyecto, destacando aspectos como el uso de datasets públicos heterogéneos, el tamaño reducido de algunas muestras y la simplificación del modelo de priorización. Estas limitaciones se consideraron relevantes de cara a futuras mejoras del pipeline. Durante esta semana también se organizaron los resultados obtenidos, incluyendo tablas y visualizaciones generadas en fases anteriores, con el objetivo de facilitar su presentación y comprensión dentro de la memoria final.

Finalmente, se elaboraron las conclusiones del proyecto, reflexionando sobre el aprendizaje adquirido durante las prácticas, tanto a nivel técnico como clínico. En particular, se destacó la importancia de integrar herramientas bioinformáticas en el ámbito de la nefrología, así como el valor de los análisis *in silico* en entornos donde no se dispone de infraestructura experimental.

Esta última fase permitió cerrar el proyecto de forma coherente, integrando todos los elementos desarrollados y consolidando un flujo de trabajo reproducible y aplicable en un contexto real de bioinformática.

Durante la integración final del flujo de trabajo fue necesario revisar la compatibilidad entre los resultados obtenidos en las distintas fases del proyecto, así como la coherencia entre los datos, las salidas generadas y la documentación producida durante el desarrollo. Esta revisión permitió detectar pequeños ajustes necesarios en formato, organización y trazabilidad, consolidando finalmente un pipeline más consistente, estructurado y reproducible.

6. RESULTADOS

A lo largo del desarrollo del proyecto se obtuvieron resultados cuantitativos, estructurados y reproducibles derivados de la ejecución del pipeline bioinformático implementado.

En términos generales, el pipeline analizó un total de 10 genes incluidos en un dataset controlado de prueba, diseñado para validar el comportamiento técnico del flujo de trabajo. El 100 % de los genes evaluados cumplió criterios de significación estadística ($p_{adj} < 0,05$). De ellos, 8 genes fueron clasificados como sobreexpresados (upregulated) y 2 como infraexpresados (downregulated), sin identificarse genes no significativos durante esta fase inicial del análisis.

Asimismo, el sistema de priorización permitió clasificar los genes según su relevancia renal, identificándose 5 genes con alta relevancia y 5 con relevancia media. Esta estrategia permitió generar un ranking estructurado orientado a facilitar la identificación de genes potencialmente relacionados con procesos biológicos de interés en el contexto de la glomerulonefritis.

El desarrollo del score de priorización permitió ordenar los genes en función de diferentes criterios integrados, incluyendo la magnitud del cambio de expresión ($\log_2$ fold change), la significación estadística y la relevancia renal asignada. Como resultado, se generó una tabla reproducible en formato TSV, constituyendo la principal salida del pipeline y permitiendo su reutilización en futuras etapas de análisis.

Entre los genes mejor posicionados destacaron IL6, NPHS1, COL4A4 y TNF. La selección de estos genes mostró coherencia conceptual con procesos descritos en la literatura relacionados con inflamación, alteraciones podocitarias y componentes estructurales del glomérulo. Estos resultados permitieron comprobar que el sistema de priorización era capaz de generar rankings biológicamente plausibles dentro del contexto formativo del proyecto.

La interpretación biológica de estos genes se realizó exclusivamente con fines educativos y de validación conceptual del pipeline. Por tanto, los resultados no deben interpretarse como evidencia clínica directa, validación funcional de biomarcadores ni hallazgos con aplicabilidad diagnóstica o terapéutica, dado el carácter exploratorio y formativo del trabajo desarrollado.

Desde el punto de vista visual, se generaron representaciones gráficas orientadas a facilitar la interpretación de los resultados. Estas visualizaciones permitieron identificar de manera más intuitiva los genes con mayor puntuación dentro del ranking de priorización y representar de forma esquemática las distintas etapas del flujo de trabajo implementado.

Aunque el dataset utilizado fue reducido y controlado, su finalidad principal consistió en validar el funcionamiento técnico, la reproducibilidad y la trazabilidad del pipeline antes de una posible adaptación a conjuntos de datos de mayor complejidad. Este enfoque permitió detectar incidencias, validar estructuras de salida y garantizar coherencia metodológica durante el desarrollo progresivo del proyecto.

En conjunto, los resultados obtenidos demuestran que el pipeline es capaz de procesar datos de expresión génica, generar métricas de priorización y producir salidas estructuradas y reproducibles tanto en formato tabular como gráfico. A pesar de tratarse de un entorno formativo y simplificado, el comportamiento del flujo de trabajo fue consistente y permitió establecer una base sólida para futuras aplicaciones sobre datasets más amplios y complejos dentro del ámbito de la bioinformática.




Figura 1. Top genes priorizados según score de relevancia.

Representación gráfica de los genes mejor clasificados en función del score de priorización calculado a partir de la expresión génica, la significación estadística y la relevancia renal.

Reproducible Bioinformatics Pipeline




Figura 2. Esquema del pipeline bioinformático reproducible.

Representación del flujo de trabajo implementado desde la entrada de datos hasta la generación de resultados priorizados y visualizaciones reproducibles.

Example TSV Output

gene	log2FC	padj	renal_relevance
NPHS1	2.6	0.0008	high
WT1	1.9	0.015	high
IL6	3.5	0.0002	medium
TNF	2.9	0.002	medium
UMOD	-2.0	0.025	high
COL4A4	-2.8	0.0015	high
CXCL8	3.1	0.003	medium
MMP9	2.4	0.008	medium
TGFB1	1.7	0.02	high
VEGFA	1.5	0.03	medium

Figura 3. Ejemplo de salida en formato TSV.

Ejemplo de la salida estandarizada generada por el pipeline, diseñada para facilitar la reutilización de los resultados en análisis posteriores y la verificación de la reproducibilidad del flujo de trabajo.

6.1 LIMITACIONES

El presente proyecto presenta diversas limitaciones que deben ser consideradas al interpretar los resultados obtenidos.

En primer lugar, el uso de datasets públicos o estructurados con fines formativos implica un riesgo de heterogeneidad en la estructura y calidad de los datos, lo que puede introducir sesgos en el análisis. La falta de estandarización entre fuentes constituye una limitación inherente a este tipo de estudios *in silico*.

En segundo lugar, el sistema de priorización implementado se basa en un enfoque simplificado sustentado en reglas y criterios de scoring. Aunque este enfoque favorece la interpretabilidad y la reproducibilidad del análisis, no incorpora metodologías estadísticas avanzadas ni técnicas de aprendizaje automático que podrían aportar un nivel adicional de complejidad analítica.

Asimismo, los resultados obtenidos no han sido validados experimentalmente, por lo que deben considerarse exploratorios. La ausencia de validación en laboratorio o en cohortes clínicas independientes limita la generalización de los hallazgos y su posible aplicación fuera del contexto formativo del proyecto.

Por otro lado, el tamaño reducido del dataset utilizado durante las fases iniciales limita la robustez del análisis y puede afectar la estabilidad del ranking generado por el sistema de priorización.

Adicionalmente, los datasets empleados durante el desarrollo fueron diseñados principalmente para validar la lógica computacional, la trazabilidad y la reproducibilidad del pipeline, y no para realizar inferencias biológicas definitivas. Por este motivo, los resultados deben interpretarse como una demostración metodológica reproducible del funcionamiento del flujo de trabajo.

Finalmente, el pipeline no contempla aspectos avanzados del análisis transcriptómico, como la corrección de efectos de batch, la integración multi-ómica, el análisis funcional automatizado o la validación en cohortes independientes, constituyendo posibles líneas de mejora para futuros desarrollos.

A pesar de estas limitaciones, el proyecto cumple satisfactoriamente su objetivo formativo, proporcionando un flujo de trabajo reproducible, trazable y coherente para la priorización génica en un contexto bioinformático aplicado a enfermedades renales.

7. CONCLUSIONES

El desarrollo de este proyecto permitió implementar un pipeline bioinformático reproducible orientado a la priorización de genes en glomerulonefritis, integrando conocimientos de programación, análisis de datos y fundamentos biomédicos dentro de un mismo flujo de trabajo.

Desde el punto de vista técnico, se construyó un sistema capaz de procesar datos estructurados de expresión génica, aplicar criterios de clasificación y generar un ranking de genes basado en un score de priorización que combina magnitud de expresión, significación estadística y relevancia renal. Este enfoque permitió transformar un análisis descriptivo en un procedimiento estructurado, reproducible y fácilmente interpretable.

La utilización de Python como entorno principal de desarrollo, complementada con actividades exploratorias en R orientadas a la comprensión de metodologías transcriptómicas, permitió ampliar la visión sobre diferentes herramientas empleadas habitualmente en bioinformática y reforzó la comprensión de los principios fundamentales del análisis de expresión diferencial.

En términos de resultados, el pipeline demostró ser capaz de generar rankings génicos coherentes desde una perspectiva conceptual y biológica, validando el funcionamiento de la estrategia de priorización implementada. Aunque el proyecto tuvo un carácter formativo y utilizó datasets estructurados de complejidad limitada, los resultados obtenidos fueron consistentes con los objetivos planteados y permitieron verificar la correcta funcionalidad del flujo de trabajo.

Más allá de los resultados específicos, uno de los principales aportes del proyecto fue la consolidación de un enfoque reproducible, donde cada etapa del análisis quedó documentada, trazada y susceptible de ser reutilizada o ampliada. Este aspecto resulta especialmente relevante en bioinformática, disciplina en la que la reproducibilidad constituye uno de los pilares fundamentales del trabajo científico.

Desde una perspectiva aplicada, el proyecto permitió establecer un vínculo entre el análisis computacional y la interpretación biomédica, mostrando cómo las herramientas bioinformáticas pueden contribuir a la exploración de problemas relacionados con enfermedades renales y a la generación de hipótesis para futuras investigaciones.

En conjunto, las prácticas permitieron aplicar de forma integrada los conocimientos adquiridos durante el Máster en Bioinformática, fortalecer competencias en programación, análisis de datos, reproducibilidad y documentación técnica, y desarrollar una base sólida para futuros proyectos en bioinformática aplicada a la nefrología.

Asimismo, la experiencia adquirida durante estas prácticas proporcionó una base metodológica relevante para el desarrollo posterior de trabajos más avanzados en transcriptómica renal, permitiendo evolucionar desde entornos formativos basados en datasets estructurados hacia análisis reproducibles realizados sobre datos transcriptómicos reales.

8. BIBLIOGRAFÍA

- Smyth, G. K. (2004). Linear models and empirical Bayes methods for assessing differential expression in microarray experiments. *Statistical Applications in Genetics and Molecular Biology*, 3(1), Article 3. <https://doi.org/10.2202/1544-6115.1027>
- Love, M. I., Huber, W., & Anders, S. (2014). Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, 15(12), 550. <https://doi.org/10.1186/s13059-014-0550-8>
- Robinson, M. D., McCarthy, D. J., & Smyth, G. K. (2010). edgeR: A Bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics*, 26(1), 139–140. <https://doi.org/10.1093/bioinformatics/btp616>
- Ritchie, M. E., Phipson, B., Wu, D., Hu, Y., Law, C. W., Shi, W., & Smyth, G. K. (2015). limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Research*, 43(7), e47. <https://doi.org/10.1093/nar/gkv007>
- Edgar, R., Domrachev, M., & Lash, A. E. (2002). Gene Expression Omnibus: NCBI gene expression and hybridization array data repository. *Nucleic Acids Research*, 30(1), 207–210. <https://doi.org/10.1093/nar/30.1.207>
- Subramanian, A., Tamayo, P., Mootha, V. K., Mukherjee, S., Ebert, B. L., Gillette, M. A., Paulovich, A., Pomeroy, S. L., Golub, T. R., Lander, E. S., & Mesirov, J. P. (2005). Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, 102(43), 15545–15550. <https://doi.org/10.1073/pnas.0506580102>
- Kopp, J. B., Anders, H.-J., Susztak, K., Podestà, M. A., Remuzzi, G., Hildebrandt, F., & Romagnani, P. (2020). Podocyte biology and glomerular disease. *Journal of the American Society of Nephrology*, 31(12), 2769–2788. <https://doi.org/10.1681/ASN.2020030277>

- Eddy, A. A. (2014). Overview of the cellular and molecular basis of kidney fibrosis. *Kidney International Supplements*, 4(1), 2–8. <https://doi.org/10.1038/kisup.2014.2>
- Ruiz-Ortega, M., Rayego-Mateos, S., Lamas, S., Ortiz, A., & Rodrigues-Diez, R. R. (2020). Targeting inflammation to treat chronic kidney disease. *Journal of Clinical Medicine*, 9(2), 451. <https://doi.org/10.3390/jcm9020451>
- National Center for Biotechnology Information. (n.d.). *Gene Expression Omnibus (GEO)*. Retrieved March 23, 2026, from <https://www.ncbi.nlm.nih.gov/geo/>